

비정상성 금융 시장 내 다중 에이전트 강화학습 전략 적응성 비교 연구

양민주*, 황병찬**, 김도겸†, 김진수***, 유민우*, 임수빈****

Comparative Analysis of Adaptive MARL Strategies in Non-Stationary Financial Markets

Minju Yang*, Byungchan Hwang**, Dogyeom Kim†, Jinsoo Kim***, Minwoo You*, Subin Lim****

요 약

월마트(Walmart)의 판매 데이터를 기반으로 구축된 복잡한 비정상성(Non-Stationary) 시장 환경에서 다중 에이전트 강화학습(MARL) 모델들의 적응력과 생존 전략을 실증적으로 비교, 분석하였다. 금융 시장에서 빈번하게 관찰되는 ‘밀도 패러독스’를 규명하기 위해, 전통적 밴딧(MAB) 알고리즘부터 베イズ 추론 기반 모델에 이르는 총 57종의 알고리즘 집단을 구성하였다. TrueSkill 기반 상대 평가 시스템을 도입하여 각 강화학습 알고리즘의 성능을 정량적으로 평가하여, 지수 감쇠 기반의 Decaying Epsilon-Greedy 알고리즘과 Thompson Collision-Aware 모델의 전략적 우수성을 확인하였다.

Abstract

This study empirically compares and analyzes the adaptability and survival strategies of Multi-Agent Reinforcement Learning(MARL) models within a complex, non-stationary market environment constructed using actual Walmart sales data. To investigate the ‘Density Paradox’ frequently observed in financial markets, a cohort of 57 algorithms was configured, ranging from traditional Multi-Armed Bandit(MAB) algorithms to Bayesian inference-based models. By introducing a TrueSkill-based relative evaluation system to quantitatively assess the performance of each algorithm, this research confirms the strategic superiority of the exponential decay-based Decaying Epsilon-Greedy algorithm and the proposed Thompson Collision-Aware model.

Key words

Multi-Agent Reinforcement Learning (MARL), Multi-Armed Bandit (MAB), Non-Stationary Market

* 한양대학교 산업공학과, yang041109@naver.com, minwoo8441@hanyang.ac.kr

** 한양대학교 데이터사이언스전공, mrbchwang@hanyang.ac.kr

† 한양대학교 컴퓨터소프트웨어학부, dogyecom74@gmail.com (교신저자)

*** 한양대학교 심리뇌과학전공, dwlstn316@hanyang.ac.kr

**** 한양대학교 정보시스템학과, sdream153@hanyang.ac.kr

I. 서 론

현대 소매 시장은 소비자 선호도의 급격한 변화, 계절적 수요 패턴, 경쟁사의 가격 전략, 그리고 팬데믹이나 공급망 차질과 같은 외부 충격으로 인해 전례 없이 복잡하고 불확실한 의사결정 환경을 형성하고 있다. 이러한 환경에서 기업은 제한된 자원의 배분, 집중 제품 선정, 전략 전환 시점 등에 관한 실시간 의사결정을 지속적으로 수행해야 한다.

이와 같은 의사결정 문제는 강화학습의 고전적 프레임워크인 Multi-Armed Bandit(MAB) 문제로 효과적으로 모델링될 수 있다 [1]. MAB의 핵심 과제는 현재까지 알려진 최선의 선택을 반복하는 Exploitation과, 더 나은 대안을 탐색하는 Exploration 사이의 균형을 찾는 것이다. 이 탐색-활용 딜레마는 소매 재고 관리, 동적 가격 결정, 마케팅 캠페인 최적화, 추천 시스템 등 다양한 실무 영역에서 공통적으로 나타나며, 그 균형점을 어떻게 설정하느냐는 기업의 수익성과 경쟁력에 직결된다.

그러나 기존 MAB 연구의 주류를 이루는 전통적 알고리즘들인 Epsilon-Greedy, UCB, Thompson Sampling 등은 각 선택지(Arm)의 기대 보상이 시간에 따라 고정되어 있다는 정상성 가정에 기반한다. 이 가정은 이론적 분석을 단순화하고 수렴을 보장하는 장점이 있지만, 실제 시장 환경과는 현격한 괴리가 있다.

II. 비정상성 금융 시장 환경 모델링

실제 금융 및 소매 시장은 거시 경제의 변화, 소비 트렌드의 전환, 예상치 못한 외부 충격 등으로 인해 통계적 특성이 끊임없이 변화하는 고도의 비정상성(Non-Stationary)을 띤다 [2]. 본 연구에서는 이러한 현실 복잡성을 시뮬레이션에 반영하기 위해, 실제 월마트 소매 판매 데이터를 가공하여 베이스라인 환경을 구축하였다. 총 1,941일의 장기 데이터를 기반으로 구축된 이 환경은, 단순한 무작위적 노이즈를 넘어 실제 시장에서 관찰되는 급격한 국면 전환과 장기적 추세 변화를 내포하고 있다. 이는 에이전트들에게 고정된 패턴 암기를 허용하지 않고,

급격한 시장 속에서의 실시간 적응력과 전략적 강건성을 평가하기 최적의 환경을 제시한다 [3].

에이전트의 의사결정 프로세스는 마르코프 결정 과정을 기반으로 하되, 비정상적 보상 구조를 가진 다중 선택지 문제로 구체화한다 [4]. 시점 t 마다 에이전트는 가용한 K 개의 상품 카테고리 집합 중 최적이라고 판단되는 하나의 행동을 취한다. 에이전트가 관측하는 상태 s_t 는 이전 시점까지의 보상 이력과 현재 시장의 변동성 정보를 포함하며 (1), 행동의 결과로 주어지는 보상 r_t 는 해당 일자의 실제 판매 수익에 기초하여 산출된다 (2). 특히 보상 함수는 시간에 따라 확률 분포의 모수(Parameter)가 변화하는 함수로 정의되어, 에이전트에게 과거의 최적해가 현재에도 유효한지 끊임없이 탐색(Exploration)하고 검증할 것을 수학적으로 요구한다.

$$s_t = \langle H_{t-1}, \nu_t \rangle \quad (1)$$

$$r_t \sim R(a_t, t) \quad (2)$$

본 연구는 단일 에이전트가 환경과 독점적으로 상호작용하는 기존 연구와 달리, N 개의 다중 에이전트가 동일한 시장 환경을 공유하며 상호작용한다. 시점 t 에서 각 에이전트 I 가 자산(Arm)을 선택하면, 환경은 전체 에이전트의 행동 분포를 수집한다. 즉, 특정 자산 k 에 배정된 총유동성은 해당 자산을 선택한 에이전트의 수 $N_{k(t)}$ 에 의해 결정된다. 이는 에이전트의 보상이 단순히 환경의 내재적 확률 분포에 의해서만 결정되는 것이 아니라, 동시간대에 참여하는 타 에이전트들의 집단적 의사결정에 의해 실시간으로 변동되는 게임 이론적 생태계를 형성한다 [5].

현실의 금융 시장에서는 특정 자산에 막대한 자본이 몰릴 경우 유동성 부족으로 인해 체결 오차가 발생하며, 이를 시장 충격 또는 슬리피지(Slippage)라고 한다. 본 연구는 이러한 금융 법칙을 환경 내 수학적으로 구현하였다. 자산 k 의 본질적인 기대 보상이 아무리 높더라도, 해당 자산을 선택한 에이전트의 밀도 $N_{k(t)}/N$ 가 환경이 허용하는 임계 유동성을 초과할 경우 보상 감소 페널티가 부여된다. 구체적으로, 과밀화된 자산에 대해서는 기하급수적으로

증가하는 페널티 함수 $P(N_{k(t)})$ 가 적용되어 최종 보상을 삭감한다 (3).

$$R_{k,final} = \frac{R_{k,0}}{(n_k)^\gamma} \quad (3)$$

결과적으로 본 연구에서 설계한 환경은 ‘가장 수익성이 높은 자산’이 곧 ‘가장 많은 에이전트가 몰리는 자산’이 되어 오히려 전체 수익이 파괴되는 ‘밀도 패러독스(Density Paradox)’를 유발한다 [그림 1]. 따라서 본 환경에서 에이전트가 살아남기 위해서는 시장의 비정상성을 추적하는 동시에, 타 에이전트들의 군집을 피하기 위한 고도의 분산 전략이 요구된다.




그림 1. 비정상성 시장 환경에서의 다중 에이전트 배틀로얄 생태계 및 밀도 패러독스 모식도
Fig. 1. Schematic of the Multi-Agent Battle Royale Ecosystem and Density Paradox in a Non-Stationary Market Environment

III. 적응적 탐색 및 충돌 회피 알고리즘

최근 비정상적 환경을 극복하기 위해 FFT(Fast Fourier Transform) 기반 주파수 도메인 분석, 적응적 샘플링(Adaptive Sampling), 주기성 탐지 등 고급 통계 기법을 활용한 정교한 MAB 알고리즘들이 다수 제안되고 있다. 다만 실시간 환경에서 복잡한 연산 및 통계 분석의 어려움, 윈도우 크기, 주기 파라미터 등 하이퍼파라미터에 대한 최적화 의존도, 과적합 문제 등 취약점으로 인해 실제 사용에 어려움이 존재한다 [6].

앞선 문제들을 실증적으로 해결 및 검증하기 위해, 복잡도와 접근 방식이 서로 다른 총 57개의 알

고리즘 변형(Variants)을 설계하여 대규모 에이전트 집단을 구성하였다. 알고리즘 풀은 크게 네 가지 카테고리 분류된다.

1. 전통 및 휴리스틱 기반 모델: Epsilon-Greedy, UCB, Softmax 등 고전적 기법 및 인간의 심리적 의사 결정을 모사한 WSL(Win-Stay, Lose-Shift) 메커니즘.
2. 적응형 탐색 최적화 모델: 탐색 확률을 지수적으로 축소하는 Decaying Epsilon-Greedy 및 최근 데이터에 가중치를 두는 Sliding Window UCB.
3. 고급 통계 및 신호 처리 모델: 주기를 탐지하는 Periodic UCB, 주파수 도메인 분석을 통해 신뢰 구간을 조절하는 FFT-UCB(Fast Fourier Transform based UCB), 샘플링 윈도우 크기를 실시간 조정하는 AS-UCB(Adaptive Sampling UCB).
4. 베이지 추론 및 환경 인식 모델: 사후 분포(Posterior)를 업데이트하는 톰슨 샘플링(Thompson Sampling)과 타 에이전트와의 군집으로 인한 슬리피지(Slippage)와의 충돌(Collision) 여부를 확인하는 Collision-Aware Thompson Sampling.

IV. 다중 에이전트 성능 평가

논의한 다양한 탐색 및 충돌 회피 알고리즘의 성능을 검증하기 위해, 2장의 월마트 데이터를 바탕으로 다중 에이전트 배틀로얄 시뮬레이션을 100,000 에피소드 반복 수행하였다. 전통적인 단일 에이전트 금융 강화학습 연구에서는 모델의 성능을 평가하기 위해 ‘누적 절대 수익률(Cumulative Absolute Return)’을 주 지표로 사용한다. 그러나, 본 연구에서는 거시적 변동성(Noise)이 극심하고, 다중 에이전트 간의 보상 잠식과 슬리피지가 실시간으로 발생하는 복합 생태계이기에 특정 episode의 운과 시장 전체의 무작위적 호황, 불황 여부가 절대 수익률에 지대한 영향을 미친다.

이러한 평가의 왜곡을 방지하기 위해, 베이지 추론(Bayesian Inference) 기반의 상대적 실력 평가 시스템인 TrueSkill 레이팅 지표를 핵심 성과 측정 도구로 도입하였다 [7]. 시뮬레이션의 매 에피소드 종료 시점마다 각 에이전트가 획득한 수익금의 서열

(Rank)을 바탕으로 TrueSkill 점수와 불확실성을 지속적으로 업데이트하였다. 이 상대평가 프레임워크는 시장 환경 자체의 거시적 노이즈를 상쇄시킴으로써, 급변하는 비정상성 환경 속에서도 에이전트가 지닌 순수한 전략적 우위와 장기적 생존성을 검증한다.

실험은 월마트 데이터 기반 환경에 가용한 에이전트의 수를 8개에서 32개까지 변화시키며 진행되었다.




그림 2 에이전트 탐색 전략에 따른 최종 성능 평가 결과

Fig. 2. Performance Evaluation Results according to Agent Exploration Strategies

실험 결과, 참여한 전체 에이전트 군집 중 지수 감쇠형 탐색 기제를 적용한 Decaying Epsilon-Greedy 모델이 최상위의 전략 우위를 점하는 것으로 규명되었다 [그림 2]. 해당 모델은 TrueSkill 환산 점수 89.72점을 기록하였으며, 시뮬레이션 환경 전반에서 상위 30% 이내의 생존율을 79.6% 수준으로 유지하며 타 알고리즘 대비 압도적인 수익 방어력을 입증하였다.

실험 데이터 분석 결과, 초기 시점에서의 과감한 탐색은 미지의 보상 분포 내에서 최적의 자산을 식별하는 동력이 되었으며, 이후 감쇠 계수 γ 에 의해 탐색 비중을 점진적으로 축소함으로써 확보된 수익의 변동성을 최소화하였다.

표 1. 다중 에이전트 환경 알고리즘 성능 평가
Table 1. Algorithm Performance Evaluation in

Multi-Agent Environments

RL Algorithm	Score	Top 30%	Win Rate
Decaying Epsilon-Greedy ($\epsilon_0 = 0.1$)	89.72	79.69%	22.87%
Decaying Epsilon-Greedy ($\epsilon_0 = 0.01$)	89.45	74.99%	23.71%
Epsilon-Greedy ($\epsilon_0 = 0.01$)	89.23	75.97%	23.87%
Thompson Collision-Aware	88.56	80.14%	21.83%
Decaying Epsilon-Greedy ($\epsilon_0 = 0.2$)	88.06	80.20%	20.83%
Decaying Epsilon-Greedy ($\epsilon_0 = 0.2$)	87.74	78.27%	23.18%
Epsilon-Greedy ($\epsilon_0 = 0.01$)	87.46	75.14%	13.71%
Sliding Window UCB ($w = 200, c = 0.01$)	86.94	69.14%	16.74%
Sliding Window UCB ($w = 200, c = 0.01$)	86.54	71.97%	16.44%
Sliding Window UCB ($w = 200, c = 0.01$)	86.30	75.04%	15.63%

감쇠 기반 모델에 이어, Sliding Window UCB 및 톰슨 샘플링 알고리즘이 차상위권(Top 10)을 형성하였다. 이들은 일정 기간의 관측치나 사후 분포(Posterior Distribution)을 지속적으로 갱신함으로써 비정상성 환경의 추세 변화를 비교적 유연하게 추적하였다. 그러나 확률 분포의 분산이 존재하는 한 지속적인 탐색을 시도하는 알고리즘 특성상, 탐색을 강제로 차단하여 변동성을 억제한 Decaying Epsilon에 비해 특정 시점의 슬리피지 노출 위험이 높아 미세한 수익 안정성의 열위를 보였다.

반면 WSL(Win-Stay, Lose-Shift)와 같은 인간 의사결정 메커니즘과 Softmax 알고리즘은 전반적으로 하위권의 생존율을 기록하였다. 이는 비정상성 시장 특유의 노이즈와 에이전트 밀집에 따른 일시적 슬리피지를 즉각적인 패배로 오인한 결과로 규명된다. 최적의 자산을 점유하고 있음에도 일시적 보상 감소에 민감하게 반응하여 잦은 전략 교체를 유발하였고, 극단적 과탐색(Over-exploration)에 누적되는 한계를 보여주었다.




그림 3 에이전트 알고리즘별 최종 성적 및 불확실성 산점도 분석

Fig. 3. Scatter Plot Analysis of Final score and Performance Uncertainty by Agent Algorithm

시뮬레이션 환경의 비정상성은 필연적으로 에이전트의 성과 변동성을 극대화한다. 따라서 특정 알고리즘의 우수성을 입증하기 위해서는 단순한 순위 추종을 넘어, 획득한 성과가 얼마나 일관되게 유지되는지를 나타내는 안정성 검증이 필수적이다.

[그림 3]은 전체 에이전트를 대상으로 최종 성과와 불확실성의 상관관계를 나타낸 산점도이다. [표 1]에서 최상위권을 차지했던 Decaying Epsilon-Greedy 계열과 Thompson Collision-Aware 모델은 좌상단에 군집하며 타 모델들과 명확한 격차를 형성하였다.

V. 결 론

본 연구는 실제 소매 데이터를 기반으로 국면 전환과 슬리피지 페널티가 공존하는 복잡한 비정상성 시장 환경을 구축하고, 다중 에이전트 강화학습 전략의 적응성과 생존성을 실증하였다. 실험 결과, 지수 감쇠 기반 Decaying Epsilon-Greedy 알고리즘이 가장 높은 TrueSkill Score(≈ 89.7)와 상위 30% 생존율($\approx 79.6\%$) 측면에서 가장 우수한 성과를 거두었다. 이는 불확실성이 극심한 환경일수록 복잡한 패턴 학습이나 고정된 휴리스틱보다 초기의 과감한 탐색과 적응적인 탐색-활용 전환 메커니즘이 전략적 강건성 확보에 더욱 유효함을 시사한다.

또한, 본 연구는 절대적 수익 지표의 한계를 극

복하기 위해 TrueSkill 기반의 상대적 평가 프레임워크를 도입하여 시장 노이즈 속에서 에이전트 간 실질적 우위를 비교하여, 향후 딥러닝 및 메타 학습과의 결합을 통해 비정상성 대응 역량을 고도화한다면, 더욱 진보된 다중 에이전트 의사결정 성과를 창출할 수 있을 것으로 기대된다.

Data availability

<https://github.com/HanyangTechAI/2026-HAI-MARL>

참 고 문 헌

- [1] G. Burtini, J. L. Loepky, and R. Lawrence, "A survey of online experiment design with the stochastic multi-armed bandit", arXiv preprint arXiv:1510.00757, 2015.
- [2] H. Yang, X.-Y. Liu, S. Zhong, and A. Walid, "Deep reinforcement learning for automated stock trading: An ensemble strategy", Proc. 1st ACM Int. Conf. AI Finance, pp. 1-7, 2020.
- [3] X. H. Gong and D. Simchi-Levi, "Bandits atop reinforcement learning: Tackling online inventory models with cyclic demands", Management Science, 2023.
- [4] F. Trovò, D. Paladino, M. Restelli, and N. Gatti, "Sliding-window Thompson sampling for non-stationary settings", J. Artif. Intell. Res., vol. 68, pp. 311-364, 2020.
- [5] C.-A. Lehalle and C. Mouzouni, "A mean field game of portfolio trading and its consequences on perceived correlations", Working Papers hal-02003143, HAL, 2019.
- [6] N. E. Huang et al., "The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis", Proc. R. Soc. A, vol. 454, pp. 903-995, 1998.
- [7] R. Herbrich, T. Minka, and T. Graepel, "TrueSkill TM: A Bayesian Skill Rating System," NIPS, vol. 20, pp. 569-576, 2007.